

Métricas de Classificação e Validação Cruzada

Accuracy, Matriz de Confusão, F1-Score e Cross-Validation (com exemplos no Colab)

Objetivos da aula

O que você deve conseguir fazer ao final 😊

- Entender o que é Accuracy e quando ela pode enganar
- Ler uma Matriz de Confusão e identificar TP, TN, FP e FN
- Calcular e interpretar Precision, Recall e F1-Score
- Aplicar Validação Cruzada (k-fold) para estimar generalização
- Gerar gráficos no Colab para comunicar resultados



Regra de ouro: uma única métrica raramente conta a história inteira.

Exercício Prático

Classifique as pessoas exibidas a seguir em uma das classes: “feliz” ou “triste”

A



B



C



D



E



F



G



H







J

K




L



M



N



O



P



Q




R



S



T



Exercício Prático

Anote a classe real de cada exemplo como: “feliz” ou “triste”

GABARITO

A



FELIZ

B



TRISTE

C



FELIZ

D



TRISTE

E



TRISTE

F



FELIZ

G



FELIZ

H



FELIZ

I
TRISTE



J



TRISTE

K



FELIZ

L




FELIZ

M



TRISTE

N



TRISTE

O



FELIZ

P



FELIZ

Q



TRISTE

R




TRISTE

S



TRISTE

T



FELIZ

Matriz de Confusão

Matriz de Confusão

Entendendo as nomenclaturas

Tenho um sistema treinado em reconhecer Maças.
Eu apresento para meu sistema uma Maça.



Eu apresento pro sistema um abacaxi.



Sistema retorna: Maça !



ACERTOU !

VERDADEIRO
POSITIVO
(VP)

Sistema retorna: Não é Maça !



ERROU !

FALSO
NEGATIVO
(FN)

Sistema retorna: Maça !



ERROU !

FALSO
POSITIVO
(FP)

Sistema retorna: Não é Maça !



ACERTOU !

VERDADEIRO
NAGATIVO
(VN)

Exercício Prático

Monte a sua matriz de confusão

Accuracy (Acurácia)

A porcentagem de acertos no conjunto avaliado

		DOENTE	SAUDÁVEL
			
TESTE POSITIVO		(VP) 	(FP) 
Verdadeiro positivo		False positive	
TESTE NEGATIVO		(FN) 	(VN) 
Falso negativo		Verdadeiro negativo	

1. Está doente e o teste é positivo: **verdadeiro positivo** → (VP)
2. Está saudável e o teste é negativo: **verdadeiro negativo** → (VN)
3. Está saudável e o teste é positivo: **falso positivo** → (FP)
4. Está doente e o teste é negativo: **falso negativo** → (FN)

ACURÁCIA:

$$\frac{VP + VN}{TOTAL (VP+VN+FN+FP)}$$

Accuracy (Acurácia)

A porcentagem de acertos no conjunto avaliado

Definição

$$\text{Accuracy} = (\text{VP} + \text{VN}) / (\text{VP} + \text{VN} + \text{FP} + \text{FN})$$

Quando funciona bem


- Boa quando as classes são balanceadas
- Boa quando o custo de FP e FN é parecido

Armadilha clássica

- Dados desbalanceados: 99% da classe 0
- Modelo “sempre 0”: accuracy alta, mas recall da classe 1 = 0

⚠ Se o seu problema tem “rara importante”, olhe além da accuracy.

Mini-exemplo (classe rara)



Accuracy é útil, mas não é onisciente. Combine com recall e F1.

Exercício Prático

Calcule a sua acurácia

Matriz de Confusão

O mapa dos acertos e erros por classe

Para binária (classe positiva = 1):

VN (Verdadeiro Negativo)	FP (Falso Positivo)
FN (Falso Negativo)	VP (Verdadeiro Positivo)

Linha = real | Coluna = previsto

💡 Cada célula é um tipo de erro. O que custa mais no seu caso: FP ou FN?

Como interpretar

- FP alto: muitos alarmes falsos (custo: tempo, atrito)
- FN alto: muitos casos perdidos (custo: risco, perda)
- Threshold muda o equilíbrio entre FP e FN

Onde isso aparece

- A matriz é base para Precision, Recall (sensibilidade) e F1
- Em multi-classe, vira uma matriz N×N

Além da Acurácia

Precisão e Sensibilidade

Fórmulas (classe positiva)

Dos positivos reais, quantos eu consegui achar (RECALL) ?

		DOENTE	SAUDÁVEL
TESTE POSITIVO	DOENTE	(VP)	(FP)
	SAUDÁVEL	Verdadeiro positivo	Falso positivo
TESTE NEGATIVO	DOENTE	(FN)	(VN)
	SAUDÁVEL	Falso negativo	Verdadeiro negativo



A **Sensibilidade** do teste é a proporção entre o número de doentes que o teste consegue detectar (VP) e o número total de doentes (ND). Em outras palavras, é a probabilidade de o teste ser positivo para uma pessoa doente: $P(\text{Teste}+\text{doente})$.

Dos positivos que eu marquei, quantos eram de verdade (PRECISION)?



A **Precisão** (ou valor preditivo positivo) é a relação entre a quantidade de pessoas doentes que testaram positivo (VP) e o número total de testes positivos (N^+). Em outras palavras, é a probabilidade de você estar doente, dado que o teste deu positivo: $P(\text{Doente}/\text{Teste}+)$.

Exercício Prático

Calcule a sua precisão e sensibilidade

F1-Score

Média Harmônica entre precisão e sensibilidade

Fórmulas (classe positiva)

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

💡 Pode punir o modelo quando um dos dois (precision ou recall) é baixo.

Exemplos práticos

- Spam: priorize precision
- Diagnóstico: priorize recall
- Quando em dúvida: F1 (e olhe a matriz)

Intuição rápida

- F1: equilíbrio quando você precisa dos dois

É crucial para conjuntos de dados desbalanceados, equilibrando o custo de falsos positivos e falsos negativos. A pontuação varia de 0 (péssimo) a 1 (excelente).

Por que usar: Diferente da acurácia, o F1-Score não é enganado se uma classe dominar o conjunto de dados.

Aplicações: Ideal para diagnósticos médicos, recuperação de informações e classificação binária onde o equilíbrio é necessário.

Exercício Prático

Calcule o seu F1-score

Exemplo no Colab: treino e métricas

Dataset: Breast Cancer (scikit-learn)

O que faremos

- Carregar dados prontos (sem download)
- Treinar Logistic Regression com Pipeline
- Gerar previsões no teste

⚙️ Rode em um Runtime CPU no Colab. É rápido.


Código (Colab)

```
1 from sklearn.datasets import load_breast_cancer
2 from sklearn.model_selection import train_test_split
3 from sklearn.pipeline import make_pipeline
4 from sklearn.preprocessing import StandardScaler
5 from sklearn.linear_model import LogisticRegression
6
7 X, y = load_breast_cancer(return_X_y=True)
8 X_tr, X_te, y_tr, y_te = train_test_split(
9     X, y, test_size=0.25, stratify=y, random_state=42
10 )
11
12 model = make_pipeline(StandardScaler(),
13 LogisticRegression(max_iter=2000))
14 model.fit(X_tr, y_tr)
15 pred = model.predict(X_te)
```


Exemplo: resultados e gráfico

Matriz de confusão + métricas no conjunto de teste

Matriz de confusão (teste)



Métricas (teste)



Código (Colab)

```
1 from sklearn.metrics import (accuracy_score,  
precision_score,  
recall_score, f1_score, confusion_matrix)  
2  
4 acc = accuracy_score(y_te, pred)  
5 prec = precision_score(y_te, pred)  
6 rec = recall_score(y_te, pred)  
7 f1 = f1_score(y_te, pred)  
8 cm = confusion_matrix(y_te, pred)  
10 acc, prec, rec, f1, cm
```

Validação Cruzada (k-fold)


Estimando performance de generalização com menos “sorte”

Ideia

- Divilde o dataset em k partes (folds)
- Treine em $k-1$ folds e teste no fold restante
- Repita k vezes e compute média e desvio padrão
- Use StratifiedKFold quando houver desbalanceamento

💡 CV é ótima para comparar modelos e hiperparâmetros. Guarde um teste final separado.

Exemplo: Accuracy por fold (k=5)




Exemplo no Colab: cross_validate

Calculando métricas em k-fold e gerando gráficos

Código (Colab)

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from sklearn.model_selection import StratifiedKFold, cross_validate
4
5 cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
6 res = cross_validate(model, X, y, cv=cv,
7                      scoring=['accuracy', 'precision', 'recall', 'f1'])
8
9 accs = res['test_accuracy']
10 print('accuracy média:', accs.mean(), '±', accs.std())
11
12 plt.plot(range(1, len(accs)+1), accs, marker='o')
13 plt.axhline(accs.mean(), linestyle='--')
14 plt.xticks(range(1, len(accs)+1))
15 plt.xlabel('Fold')
16 plt.ylabel('Accuracy')
17 plt.title('Accuracy por fold (CV)')
18 plt.show()
```

Gráfico (exemplo)



Dica: salve os resultados em um DataFrame para facilitar gráficos mais bonitos.

Exercício (mão na massa)

Dataset: Wine (3 classes) para vocês criarem seus próprios gráficos

Tarefas

- Carregue o dataset Wine e faça um train/test split estratificado
- Treine um modelo (LogReg, RandomForest, SVM...)
- Calcule accuracy e matriz de confusão (3×3) e plote o heatmap
- Calcule F1 macro e F1 weighted e compare
- Faça validação cruzada ($k=5$) para accuracy e F1 macro
- Gere 2 gráficos: matriz de confusão e performance por fold

Starter code (Colab)

```
1 from sklearn.datasets import load_wine
2 from sklearn.model_selection import train_test_split,
StratifiedKFold, cross_validate
3 from sklearn.metrics import ConfusionMatrixDisplay, f1_score
4 from sklearn.ensemble import RandomForestClassifier
5 import matplotlib.pyplot as plt
6
7 X, y = load_wine(return_X_y=True)
8 X_tr, X_te, y_tr, y_te = train_test_split(
9     X, y, test_size=0.25, stratify=y, random_state=42
10 )
11
12 clf = RandomForestClassifier(random_state=42)
13 clf.fit(X_tr, y_tr)
14 pred = clf.predict(X_te)
15
16 # 1) Matriz de confusão
17 ConfusionMatrixDisplay.from_predictions(y_te, pred)
18 plt.title('Wine: matriz de confusão')
19 plt.show()
20
21 # 2) F1 macro vs weighted
22 print('F1 macro    : ', f1_score(y_te, pred, average='macro'))
23 print('F1 weighted: ', f1_score(y_te, pred, average='weighted'))
24
25 # 3) CV + gráfico por fold
26 cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
27 res = cross_validate(clf, X, y, cv=cv,
scoring=['accuracy', 'f1_macro'])
28
29 plt.plot(res['test_accuracy'], marker='o', label='accuracy')
30 plt.plot(res['test_f1_macro'], marker='o', label='f1_macro')
31 plt.legend(); plt.title('Performance por fold')
32 plt.xlabel('Fold'); plt.show()
```

Boas práticas (checklist rápido)

Para não cair em “números bonitos” 

- Separe um conjunto de teste final e não “olhe” para ele durante ajustes
- Use Pipeline para evitar vazamento de dados (scaler só com treino)
- Sempre inspecione a matriz de confusão (por classe)
- Em desbalanceamento: prefira F1, precision/recall e métricas macro
- Em CV: reporte média e desvio padrão, não só a média
- Escolha a métrica alinhada ao custo real do erro (FP vs FN)

Resumo em 4 frases

- Accuracy é um resumo, não um veredito.
- A matriz de confusão mostra onde o modelo erra.
- F1 combina precision e recall quando ambos importam.
- Validação cruzada reduz a dependência de um único split.